MCDI501
ESTADÍSTICA COMPUTACIONAL
SUMATIVA 1
INFORME TÉCNICO DE AVANCE DEL PROYECTO

Grupo 7 - Factores asociados con la puntualidad de envíos en comercio electrónico
E-Commerce Shipping / Customer Analytics

Integrantes: Felipe Palma Barrientos · Vicente Aguila Rojas · Cristian Grandon Grandon · Jorge Gutierrez Jaramillo
Curso: MCDI501 · Estadística Computacional
Programa: Magíster en Ciencia de Datos e Inteligencia Artificial
Fecha: 12 de octubre de 2026
Repositorio: github.com/jorge170102/ESTAD-STICA-COMPUTACIONAL---Grupo-7--MCDI501.202682.1914.EL.ON
Chile, octubre de 2026

I. Portada e índice

I. Portada e índice **2**
II. Introducción y contextualización **3**
III. Definición del problema y objetivos **3**
IV. Aplicación de herramientas científicas y metodología **4**
4.1. Entorno científico y arquitectura modular 4
4.2. Procedimiento y criterios estadísticos 4
4.3. Trazabilidad y reproducibilidad 4
V. Preparación y auditoría de datos **5**
VI. Análisis exploratorio y relaciones bivariadas **5**
6.1. Estadística descriptiva 5
6.2. Relaciones bivariadas y visualizaciones 6
VII. Estimación puntual e intervalos de confianza **7**
VIII. Pruebas de hipótesis **7**
8.1. Modo de envío y puntualidad: chi-cuadrado 7
8.2. Peso promedio y puntualidad: t de Welch 7
IX. Discusión, conclusiones y líneas de mejora **8**
9.1. Discusión integrada 8
9.2. Limitaciones y alcance 8
9.3. Conclusiones y continuidad 9
X. Bibliografía y reproducibilidad **10**
10.1. Fuentes de datos y documentos 10
10.2. Acceso al proyecto y trazabilidad 10
10.3. Procedimiento de reproducción 10

II. Introducción y contextualización

¿Cómo puede el análisis de datos contribuir a mejorar la puntualidad de las entregas en el comercio electrónico?

El cumplimiento de los plazos es una dimensión relevante del servicio logístico. Comprender cómo se relaciona con las características de los envíos permite identificar patrones y orientar posibles mejoras, considerando la incertidumbre de los resultados.

Este proyecto analiza 10.999 registros y 12 variables del conjunto E-Commerce Shipping / Customer Analytics mediante estadística descriptiva e inferencial. Se estudian la proporción de entregas fuera de plazo, las distribuciones de las variables y las asociaciones de la puntualidad con el medio de transporte y el peso del producto. El análisis es reproducible, observacional y exploratorio, por lo que sus resultados no permiten establecer relaciones causales.

Síntesis ejecutiva

Casi seis de cada diez envíos del conjunto analizado llegaron fuera de plazo (59,67 %). Los resultados no respaldan priorizar un cambio de transporte para mejorar la puntualidad, dada la escasa asociación observada (V de Cramér = 0,008; p = 0,690). En cambio, orientan a investigar las diferencias entre los perfiles de productos: los envíos fuera de plazo presentaron un peso medio 892,32 g menor que los puntuales (IC 95 % de la diferencia: [−955,61; −829,02] g). Antes de proponer medidas correctivas, se requiere información adicional sobre destinos, distancias y duración de los retrasos, ya que estas asociaciones no permiten identificar sus causas.

III. Definición del problema y objetivos

Problema central: la tasa general de entregas fuera de plazo no permite identificar qué características de los envíos se relacionan con la puntualidad. Se requiere analizar estas asociaciones para orientar la revisión de los procesos logísticos, sin atribuir causalidad a las diferencias observadas.

Pregunta de investigación: ¿qué asociación presentan el medio de transporte y el peso del producto con la puntualidad de entrega en el conjunto analizado?

Objetivo general: analizar las características de los envíos y su asociación con la puntualidad mediante estadística descriptiva e inferencial, para aportar evidencia que oriente posibles mejoras en el cumplimiento de los plazos, utilizando un procedimiento documentado y reproducible.

Objetivos específicos:

- Evaluar la estructura y calidad de los datos, documentando sus dominios, integridad y generación controlada de valores faltantes MCAR.
- Caracterizar las distribuciones de las variables y explorar sus relaciones con el estado de entrega.
- Estimar las medias de peso, costo y descuento mediante intervalos de confianza del 95 %, utilizando las observaciones disponibles por variable.
- Evaluar la asociación entre transporte y puntualidad mediante chi-cuadrado, y comparar el peso medio entre entregas puntuales y fuera de plazo mediante Welch, con un nivel de significancia del 5 %.
- Interpretar los resultados y su utilidad para orientar la revisión logística, explicitando supuestos, limitaciones y necesidades de información adicional.

IV. Aplicación de herramientas científicas y metodología

4.1. Entorno científico y arquitectura modular

El proyecto utiliza Python, pandas y NumPy para procesar datos; SciPy para inferencia estadística; Matplotlib y Seaborn para visualización; Jupyter para integrar código, resultados e interpretación; y Git/GitHub para controlar versiones.

Las funciones se organizan en módulos dentro de src/, separando carga, validación, transformación, estadística descriptiva, análisis bivariado e inferencia. El notebook sumativa_1.ipynb coordina su ejecución y presenta la evidencia del análisis, facilitando su revisión y reproducción.

4.2. Procedimiento y criterios estadísticos

El proceso comienza con la auditoría del archivo original, revisando estructura, tipos de datos, identificadores, duplicados, valores faltantes y dominios de las variables. Como la base original no presenta ausencias, se genera una versión con faltantes completamente aleatorios MCAR en Weight_in_gms y Cost_of_the_Product, mediante selección sin reemplazo y semilla 42. Se retiran 1.100 valores por variable, aproximadamente el 10 %, conservando 9.899 observaciones disponibles en cada una.

La versión MCAR constituye la base del análisis descriptivo e inferencial. Se utilizan los valores disponibles por variable y los pares completos para las correlaciones, sin eliminar globalmente registros ni aplicar imputación. Los valores retirados se conservan en un archivo de auditoría para evaluar métodos de imputación en etapas posteriores.

La exploración comprende frecuencias, medidas de tendencia central y dispersión, histogramas, diagramas de caja y comparaciones por estado de entrega. Se utiliza Spearman para examinar asociaciones monotónicas, incluyendo la valoración ordinal del cliente. Los valores fuera de las cercas de 1,5 rangos intercuartílicos se identifican para revisión, sin eliminarlos automáticamente.

Se estiman las medias de peso, costo y descuento mediante intervalos t de Student del 95 %. Para los contrastes se emplean chi-cuadrado de independencia entre transporte y puntualidad, verificando las frecuencias esperadas, y t de Welch bilateral para comparar el peso medio entre estados de entrega, sin asumir igualdad de varianzas. Ambas pruebas utilizan $\alpha = 0{,}05$, sin ajuste conjunto por multiplicidad. Se reportan V de Cramér y d de Cohen para complementar la interpretación de la magnitud de las asociaciones y diferencias.

Los histogramas y gráficos Q–Q apoyan la revisión de las distribuciones. La interpretación inferencial queda condicionada a los supuestos de independencia y selección de los registros; los resultados no permiten establecer causalidad.

4.3. Trazabilidad y reproducibilidad

El archivo original se conserva en data/raw/; la versión MCAR y la auditoría de valores retirados se almacenan en data/processed/. El archivo requirements.txt especifica las dependencias y versiones declaradas. El repositorio incluye seis pruebas unitarias que verifican aspectos de preparación, reproducibilidad MCAR y procedimientos inferenciales.

Para reproducir el análisis, se debe configurar el entorno, instalar las dependencias, ejecutar las pruebas y abrir notebooks/sumativa_1.ipynb con el kernel correspondiente. La opción «Restart Kernel and Run All» ejecuta el proceso desde la carga del original, regenera MCAR con la semilla definida y produce las tablas y figuras. La comprobación final requiere contrastar estas salidas con el informe y registrar el commit y las versiones efectivamente utilizadas.

V. Preparación y auditoría de datos

La unidad de observación es el envío y la variable objetivo Reached.on.Time_Y.N se interpreta en este estudio como 0 = a tiempo y 1 = fuera de plazo. ID corresponde a un identificador, por lo que no se incorpora a correlaciones ni a estimaciones numéricas.

Tabla 1. Resultados de la auditoría y generación controlada de faltantes

Control	Resultado	Decisión metodológica
Registros / variables	10.999 / 12	Conservar la base original
Nulos originales / duplicados	0 / 0	No imputar ni eliminar registros
Faltantes MCAR por variable	1.100 (10 %)	Peso y costo del producto
Semilla de generación	42	Reproducibilidad de la selección
Observaciones válidas en peso y costo	9.899 por variable	Análisis por casos disponibles

El mecanismo MCAR se aplicó con selección aleatoria, sin reemplazo y sin utilizar el valor de la variable para decidir su ocultamiento. Los valores completos originales permanecen disponibles como referencia de auditoría para una etapa futura de imputación. Este diseño no convierte la muestra en probabilística ni resuelve incertidumbres sobre su representatividad.

VI. Análisis exploratorio y relaciones bivariadas

6.1. Estadística descriptiva

El análisis descriptivo utiliza la versión MCAR y considera los valores disponibles por variable. Se presentan medidas de tendencia central y dispersión para caracterizar las diferencias entre productos y complementar los promedios con información sobre la distribución de los datos.

Tabla 2. Medidas de tendencia central y dispersión sobre la versión MCAR

Variable	n válido	Media	DE muestral	Unidad
Llamadas de atención	10.999	4,054	1,141	Conteo
Compras anteriores	10.999	3,568	1,523	Conteo
Costo del producto	9.899	210,239	48,046	USD
Descuento ofrecido	10.999	13,373	16,206	No especificada
Peso del producto	9.899	3.633,880	1.636,133	Gramos

El descuento presenta una media de **13,373**, superior a su mediana de **7**, mientras que el 50 % central se concentra entre **4 y 10**. Este patrón, junto con los histogramas del notebook, evidencia una distribución asimétrica a la derecha: los valores elevados incrementan el promedio, por lo que conviene interpretarlo junto con la mediana.

El peso muestra una dispersión considerable: el 50 % central se encuentra entre **1.840 y 5.051 g**, con un rango intercuartílico de **3.211 g**. Esta heterogeneidad justifica examinar su distribución por estado de entrega. Los histogramas y diagramas de caja del notebook complementan estas medidas; los valores extremos se conservan conforme a las decisiones documentadas en la auditoría.

Tabla 3. Estado de entrega de los envíos

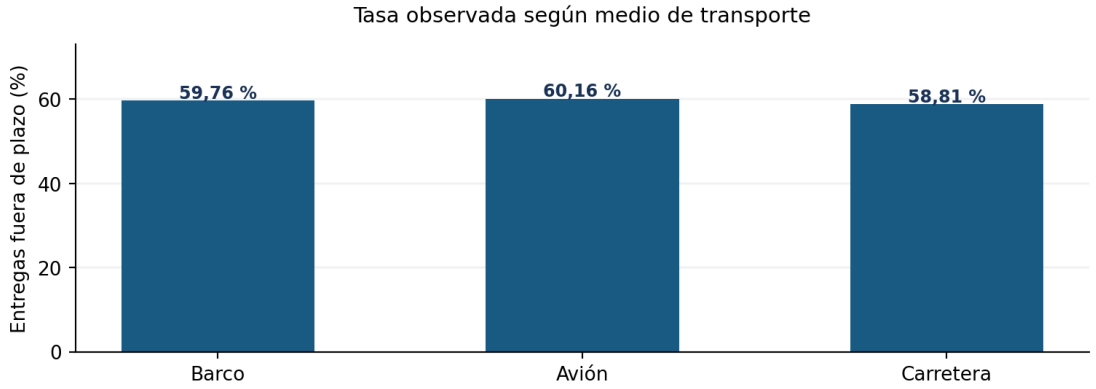
Estado	Frecuencia	Porcentaje
A tiempo (0)	4.436	40,33 %
Fuera de plazo (1)	6.563	59,67 %
Total	10.999	100,00 %

Casi seis de cada diez registros corresponden a entregas fuera de plazo. Esta proporción describe el conjunto analizado y constituye la referencia para comparar los distintos grupos de envíos; no debe interpretarse automáticamente como la tasa de retrasos de otras operaciones.

6.2. Relaciones bivariadas y visualizaciones

La matriz de correlaciones de Spearman y los resúmenes por estado de entrega complementan la descripción univariada. En particular, se comparan las tasas de entregas fuera de plazo por modo de transporte y la distribución del peso según el resultado del envío. Estos gráficos resumen patrones descriptivos, no efectos causales.

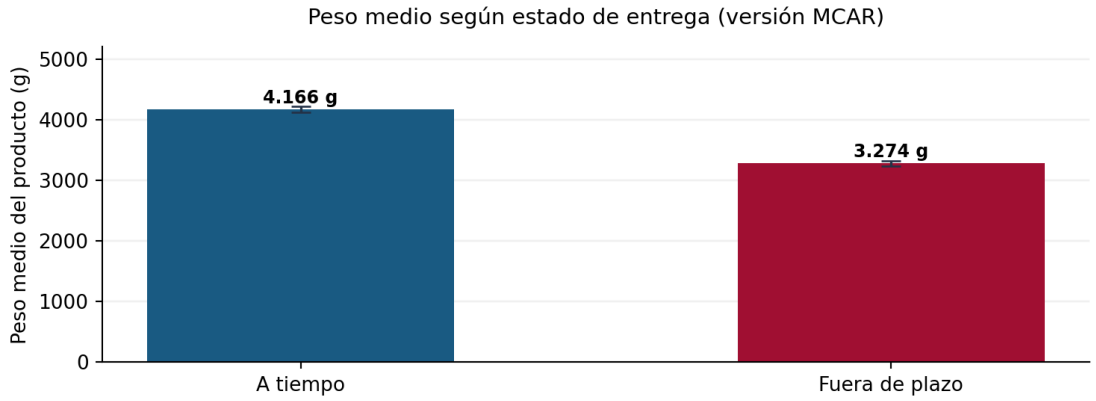
Figura 1. Porcentaje de entregas fuera de plazo según medio de transporte



Nota. Elaboración propia con datos E-Commerce Shipping. Denominadores: barco 7.462, avión 1.777 y carretera 1.760 envíos.

La mayor tasa corresponde al avión (60,16 %) y la menor a carretera (58,81 %), una diferencia descriptiva de solo 1,35 puntos porcentuales. Es necesario un contraste formal para determinar si la variación es estadísticamente distinguible de la esperable por azar bajo independencia.

Figura 2. Peso medio por estado de entrega en observaciones disponibles (MCAR)



Nota. Elaboración propia. Se excluyen solo pesos faltantes: n = 3.992 a tiempo y n = 5.907 fuera de plazo. Barras de error: ± 1,96 errores estándar, con finalidad descriptiva.

Las entregas puntuales tienen peso medio de 4.166,35 g frente a 3.274,03 g de las entregas fuera de plazo; la diferencia sin ajustar es de -892,32 g (fuera de plazo menos a tiempo).

VII. Estimación puntual e intervalos de confianza

Se construyen intervalos bilaterales para medias mediante la distribución t de Student y la desviación estándar muestral (IC = media ± t crítico × s/√n). El tamaño de muestra válido se informa por variable; la interpretación de cobertura depende de independencia, selección y variabilidad finita.

Tabla 4. Estimaciones de medias con intervalos de confianza del 95 %

Variable	n	Media	Límite inferior	Límite superior
Peso (g)	9.899	3.633,88	3.601,65	3.666,12
Costo del producto	9.899	210,24	209,29	211,19
Descuento ofrecido	10.999	13,37	13,07	13,68

Un intervalo de confianza del 95 % caracteriza la incertidumbre del estimador bajo repeticiones hipotéticas del procedimiento; no indica que el 95 % de los productos individuales se ubique entre sus límites. Los intervalos estrechos no eliminan posibles sesgos de selección.

VIII. Pruebas de hipótesis

8.1. Modo de envío y puntualidad: chi-cuadrado

H_0: el modo de envío y el estado de entrega son independientes. H_1: existe asociación. Se utiliza chi-cuadrado sobre una tabla de tres medios de transporte y dos estados, con $\alpha = 0{,}05$. La frecuencia esperada mínima es 709,82, superior al umbral habitual de 5; la independencia entre envíos depende del diseño de recolección, no de esta tabla.

Tabla 5. Contraste de independencia por medio de transporte

χ^2	gl	p	V de Cramér	Decisión ($\alpha = 0{,}05$)
0,743	2	0,690	0,008	No rechazar H_0

El p-valor de 0,690 no aporta evidencia suficiente contra la independencia entre transporte y puntualidad en estos registros. El V de Cramér de 0,008 indica una asociación observada prácticamente nula. No rechazar H_0 no significa demostrar independencia.

8.2. Peso promedio y puntualidad: t de Welch

La elección de la prueba t de Welch se fundamenta en su capacidad para comparar medias de grupos independientes sin exigir homogeneidad de varianzas. Los tamaños muestrales elevados favorecen la aproximación normal de la diferencia de medias, aunque no permiten verificar por sí solos la independencia de las observaciones.

H_0: μ fuera de plazo − μ a tiempo = 0. H_1: la diferencia es distinta de cero. Se utiliza Welch bilateral, que no exige igualdad de varianzas, con análisis gráfico de distribuciones y errores estándar. Los grupos son grandes; la independencia continúa siendo una suposición sustantiva.

8.2. Resultado de la prueba de Welch (continuación)

Tabla 6. Comparación de medias del peso según resultado del envío

Estadístico	Resultado	Interpretación
Diferencia media	−892,32 g	Fuera de plazo menos a tiempo
t de Welch	≈ −27,64	Contraste bilateral
Grados de libertad	≈ 8.576	Welch-Satterthwaite
p-valor	< 0,001	Rechazar H_0 al 5 %
IC del 95 %	[−955,61; −829,02] g	Diferencia poblacional estimada
d de Cohen	−0,566	Magnitud estandarizada moderada

La diferencia de peso es estadísticamente significativa y de magnitud apreciable. Sin embargo, el estudio no controla destinos, tipos de producto ni distancias: por tanto, la asociación encontrada no permite afirmar que cambiar el peso de un envío causaría un cambio en su puntualidad.

IX. Discusión, conclusiones y líneas de mejora

9.1. Discusión integrada

Los datos muestran que 59,67 % de los envíos aparecen fuera de plazo. El método de transporte exhibe tasas similares y un contraste no significativo; el peso sí presenta una diferencia media clara según estado de entrega. Interpretados conjuntamente, los resultados motivan examinar mecanismos logísticos adicionales, sin asumir que las variables estudiadas operen de manera independiente o causal.

9.2. Limitaciones y alcance

Los resultados aportan evidencia para comprender los patrones de puntualidad del conjunto analizado. Su interpretación debe considerar las restricciones de los datos y los supuestos estadísticos, que delimitan las conclusiones y su aplicación a decisiones operativas.

Limitaciones

Muestreo no documentado: se desconoce cómo fueron seleccionados los registros, por lo que no puede asegurarse que representen otras operaciones de comercio electrónico.

Independencia no confirmada: podrían existir envíos relacionados por cliente, ruta o periodo. Esa dependencia puede afectar los errores estándar, intervalos de confianza y pruebas de hipótesis.

Información operativa incompleta: la ausencia de destinos, distancias, fechas y duración de los retrasos limita la evaluación de explicaciones alternativas y de la gravedad de los incumplimientos.

Faltantes artificiales: el mecanismo MCAR permite estudiar ausencias controladas, pero no necesariamente reproduce cómo se pierde información en una operación real.

Unidad del descuento desconocida: impide interpretar sus valores como porcentajes o montos monetarios y evaluar directamente su significado económico.

Contrastes sin ajuste por multiplicidad: cada prueba utiliza $\alpha = 0{,}05$, pero este nivel no garantiza un error conjunto del 5 % al considerar ambas pruebas.

Alcance

Conjunto estudiado: el análisis comprende los 10.999 registros de E-Commerce Shipping / Customer Analytics, utilizando la versión MCAR y las observaciones disponibles para cada procedimiento.

Caracterización descriptiva: se describen distribuciones, frecuencias y relaciones entre variables para identificar diferencias y patrones dentro de los datos.

Evaluación inferencial: se estiman tres medias con intervalos de confianza y se contrastan las relaciones de la puntualidad con el transporte y el peso. Su interpretación depende de los supuestos declarados.

Orientación de investigaciones posteriores: los hallazgos permiten priorizar aspectos que requieren revisión e información adicional. La identificación de causas y la evaluación del efecto de medidas correctivas requieren estudios posteriores.

9.3. Conclusiones y continuidad

Conclusión general. El proyecto permitió caracterizar la puntualidad de las entregas e identificar asociaciones mediante un proceso documentado y reproducible. El **59,67 % de registros fuera de plazo** evidencia un foco de revisión en el conjunto analizado. Los resultados aportan una base para orientar investigaciones posteriores, aunque no permiten determinar las causas de los retrasos.

Conclusión técnica y estadística. No se encontró evidencia suficiente de asociación entre transporte y puntualidad (**p = 0,690; V de Cramér = 0,008**). En cambio, las entregas fuera de plazo presentan un peso medio **892,32 g menor** que las puntuales, diferencia estadísticamente significativa (**p < 0,001; IC 95 %: [−955,61; −829,02] g**). Estos resultados corresponden a los valores disponibles de la versión MCAR y deben interpretarse bajo los supuestos y limitaciones declarados.

Conclusión para la toma de decisiones. La evidencia disponible no justifica priorizar un cambio de transporte para mejorar el cumplimiento. Sí orienta a investigar los perfiles de productos y sus condiciones de despacho, considerando conjuntamente peso, descuento y características logísticas. Antes de comprometer recursos en medidas correctivas, se requiere información que permita distinguir explicaciones alternativas y evaluar el posible efecto de cada acción.

Continuidad del análisis. Se propone evaluar la robustez de los resultados mediante remuestreo, comparar métodos de imputación utilizando los valores originales reservados como referencia e incorporar información sobre destinos, distancias y duración de los retrasos. Posteriormente, los análisis multivariados permitirían examinar asociaciones ajustadas y, si se desarrollan modelos predictivos, su desempeño deberá evaluarse con datos independientes de los utilizados para entrenarlos.

X. Bibliografía y reproducibilidad

10.1. Fuentes de datos y documentos

1. Universidad Andrés Bello (2026). Sumativa 1: informe técnico de avance del proyecto [Instrucciones y rúbrica de MCDI501]. Material docente de la asignatura.

2. Kaggle. (s. f.). E-Commerce Shipping Data / Customer Analytics [Conjunto de datos]. https://www.kaggle.com/datasets/prachi13/customer-analytics

3. pandas Development Team. (s. f.). pandas documentation. https://pandas.pydata.org/docs/

4. SciPy Community. (s. f.). SciPy documentation. https://docs.scipy.org/doc/scipy/

5. NumPy Developers. (s. f.). NumPy documentation. https://numpy.org/doc/

6. Matplotlib Development Team. (s. f.). Matplotlib documentation. https://matplotlib.org/stable/

7. Python Software Foundation. (s. f.). Python documentation. https://docs.python.org/3/

10.2. Acceso al proyecto y trazabilidad

Repositorio del Grupo 7 (MCDI501): https://github.com/jorge170102/ESTAD-STICA-COMPUTACIONAL---Grupo-7--MCDI501.202682.1914.EL.ON

Tabla 7. Evidencia reproducible vinculada a la rúbrica

Elemento evaluado	Evidencia técnica
Preparación y calidad	src/carga.py, src/validacion.py, src/transformacion.py
Estadística descriptiva	Notebook: secciones de exploración y tablas
Relaciones bivariadas	src/analisis_bivariado.py y visualizaciones
Intervalos y contrastes	src/inferencia.py; notebook de inferencia
Verificación	Pruebas reejecutables en tests/
Informe técnico	Documento PDF y código en el repositorio

10.3. Procedimiento de reproducción

Desde la raíz del proyecto: Primero crear y activar un entorno virtual; Segundo instalar requirements.txt; Tercero abrir notebooks/sumativa_1.ipynb; Cuarto seleccionar el kernel correspondiente; Quinto ejecutar «Restart Kernel and Run All» y contrastar los resultados con data/processed/ecommerce_mcar.csv. Mantener el registro de valores MCAR separado y sin utilizarlo para completar artificialmente esta sumativa.

Los resultados son provisionales en términos de inferencia poblacional y deben acompañarse de la discusión de supuestos, limitaciones y alcance observacional declarada en este informe.