MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

SUMATIVA 2 · INFORME 3

Validación de resultados mediante remuestreo y simulación

Grupo 7 · Puntualidad de envíos en comercio electrónico

Felipe Palma Barrientos · Vicente Aguila Rojas · Cristian Grandon Grandon · Jorge Gutierrez Jaramillo

Universidad Andrés Bello · MCDI501 · Octubre de 2026

I. Propósito y continuidad con la Sumativa 1

La pregunta central de esta fase no consiste en encontrar nuevas asociaciones, sino en determinar hasta qué punto son confiables las conclusiones inferenciales de la Sumativa 1 (S1) cuando se cambia el procedimiento de estimación, se reorganizan etiquetas bajo una hipótesis nula o se simulan muestras plausibles. Se trata de evaluar incertidumbre, estabilidad y sensibilidad; una conclusión estadísticamente significativa no equivale, por sí sola, a un mecanismo causal.

El estudio utiliza exactamente el conjunto preparado en S1: 10.999 envíos de E-Commerce Shipping / Customer Analytics, con 1.100 valores faltantes MCAR introducidos en peso y otros 1.100 en costo. No se imputaron faltantes; cada análisis utiliza observaciones disponibles y pares completos cuando corresponde. La codificación es 0 = entrega a tiempo y 1 = fuera de plazo. La huella SHA-256 del CSV procesado se verifica antes de ejecutar el notebook.

Tabla 1. Parámetros propios de S1 que se someten a validación en S2

Resultado de S1	Estimación inicial	Pregunta de validación
Media de peso, costo y descuento	3.633,88 g; 210,24 USD; 13,37	¿Cambian los IC con bootstrap?
Peso por estado de entrega	Δ = −892,32 g; IC95 % [−955,61; −829,02]	¿Resiste permutación y simulación?
Modo de transporte y puntualidad	χ^2 = 0,743; p = 0,6895	¿Coincide la inferencia por permutación?
Tres correlaciones de Spearman	ρ por pares completos	¿Son estables y sensibles a decisiones?

Los métodos de remuestreo, permutación y Monte Carlo emplean 10.000 repeticiones por análisis, con semillas reproducibles. La implementación se separó en módulos de src/ y un notebook que presenta las tablas, figuras e interpretaciones; los resultados consolidados se exportan a un JSON para la Sumativa 3 (S3).

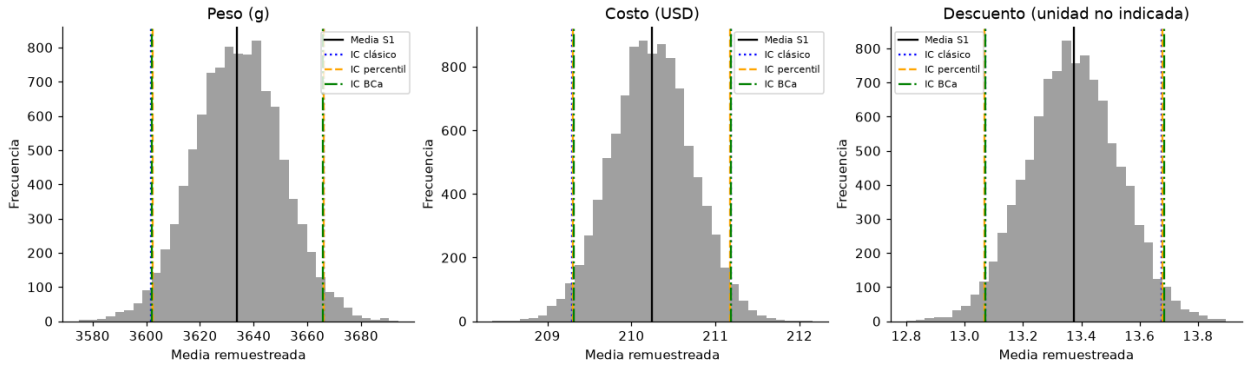
II. Bootstrap: confiabilidad de los intervalos de S1

Los intervalos clásicos de S1 se obtuvieron bajo una aproximación t para cada media, cuya interpretación supone observaciones suficientemente independientes y un mecanismo de selección apropiado. Para evaluar si las estimaciones dependen fuertemente de esa construcción paramétrica, se aplicó bootstrap no paramétrico: en cada una de 10.000 repeticiones se extrae, con reemplazo, una muestra del mismo tamaño entre los valores disponibles y se calcula su media. La distribución de estas medias permite obtener IC percentil al 95 %, así como intervalos BCa, que corrigen sesgo y aceleración (Efron y Tibshirani, 1993).

Tabla 2. Comparación de IC95 % clásicos y bootstrap, conservando los datos de S1

Variable (n)	Clásico S1	Percentil S2	BCa S2
Peso (9.899)	[3.601,65; 3.666,12]	[3.602,47; 3.666,18]	[3.602,09; 3.665,77]
Costo (9.899)	[209,29; 211,19]	[209,30; 211,17]	[209,31; 211,18]
Descuento (10.999)	[13,07; 13,68]	[13,07; 13,68]	[13,07; 13,68]

Figura 1. Distribuciones bootstrap de las medias y límites de los intervalos.



Nota. Las líneas muestran las estimaciones y los límites del 95 %; B = 10.000 por media.

Los tres enfoques entregan intervalos muy próximos. Frente al intervalo clásico, la amplitud del BCa varía −1,23 % para peso, −1,19 % para costo y +0,94 % para descuento, con desplazamientos menores a 0,05 errores estándar. Por tanto, las conclusiones sobre la precisión de las medias no dependen materialmente de escoger una u otra construcción del intervalo en esta muestra. Esta concordancia es relevante, sobre todo porque las variables presentan características distributivas diferentes.

El descuento es el caso más ilustrativo: sus observaciones tienen asimetría positiva aproximada de 1,80, pero la distribución bootstrap de la media resulta casi simétrica. Esto es compatible con la estabilización del estimador cuando el tamaño de muestra es grande, no implica que los descuentos individuales sean normales ni que sus valores altos carezcan de importancia. Tampoco convierte los intervalos en garantías de cobertura poblacional si existen dependencias o sesgos de selección que el remuestreo de registros no reproduce.

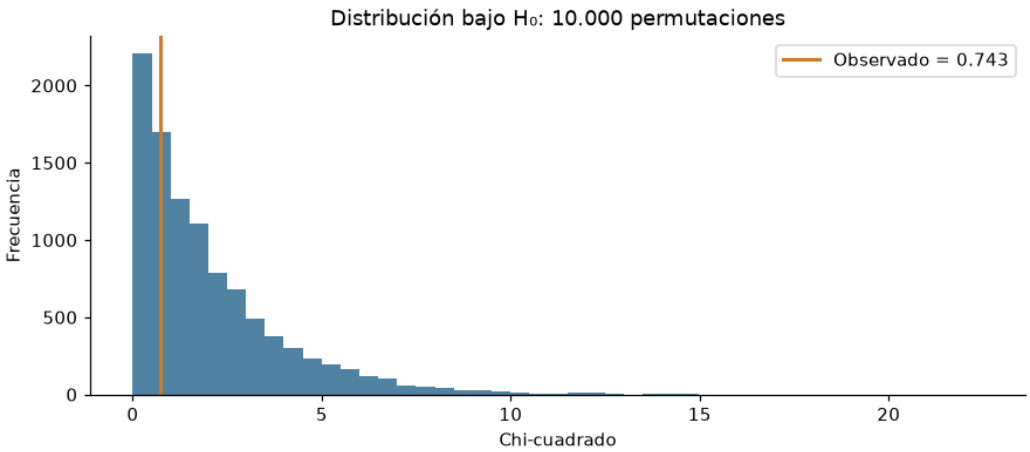
III. Permutaciones: contraste con las pruebas originales

La inferencia paramétrica de S1 fue contrastada mediante 10.000 permutaciones por hipótesis. En lugar de postular una distribución teórica para el estadístico, este procedimiento construye una distribución de referencia al reorganizar las etiquetas bajo la hipótesis nula. Se empleó la corrección (eventos al menos tan extremos + 1)/(B + 1), que evita informar un valor p igual a cero cuando el número de permutaciones es finito (Phipson y Smyth, 2010).

Independencia entre transporte y puntualidad

S1 reportó $\chi^2 = 0{,}743$ con dos grados de libertad, $p = 0{,}689549$ y V de Cramér = 0,0082. La permutación de las etiquetas de puntualidad produjo $p = 0{,}689231$. Su semejanza respalda la decisión de no rechazar la hipótesis nula al 5 %, pero no demuestra que el transporte sea independiente de la puntualidad en toda población ni que ambos modos de análisis sean equivalentes. La distribución simulada permite visualizar que un χ^2 como el observado no es raro bajo el escenario de ausencia de asociación.

Figura 2. Distribución nula de χ^2 y estadístico observado.



Nota. El valor observado (0,743) cae en una región frecuente de las 10.000 permutaciones.

Diferencia de peso entre entregas puntuales y atrasadas

En las 9.899 observaciones con peso disponible, los envíos fuera de plazo presentaron una media inferior en 892,32 g (5.907 atrasados y 3.992 puntuales). Welch estimó $p = 4{,}14 \times 10^{-161}$, un tamaño del efecto moderado (d de Cohen = −0,566) y el intervalo [−955,61; −829,02] g. En la prueba bilateral de permutación, ninguna de las 10.000 diferencias reordenadas alcanzó la magnitud observada; de acuerdo con la corrección anterior, $p \approx 0{,}0001$. Los dos enfoques rechazan igualdad de medias, aunque sus valores p tienen resoluciones muy diferentes.

La concordancia merece una precisión conceptual: permutar etiquetas directamente requiere intercambiabilidad bajo la hipótesis nula, mientras que Welch contrasta medias con varianzas posiblemente diferentes. Por ello, la permutación simple constituye una comprobación complementaria, no una sustitución universal del contraste de Welch. Asimismo, que los envíos atrasados sean más livianos contradice una explicación logística intuitiva; esta diferencia puede reflejar composición de productos u otros factores no observados. No corresponde atribuir al peso un efecto causal sobre el atraso.

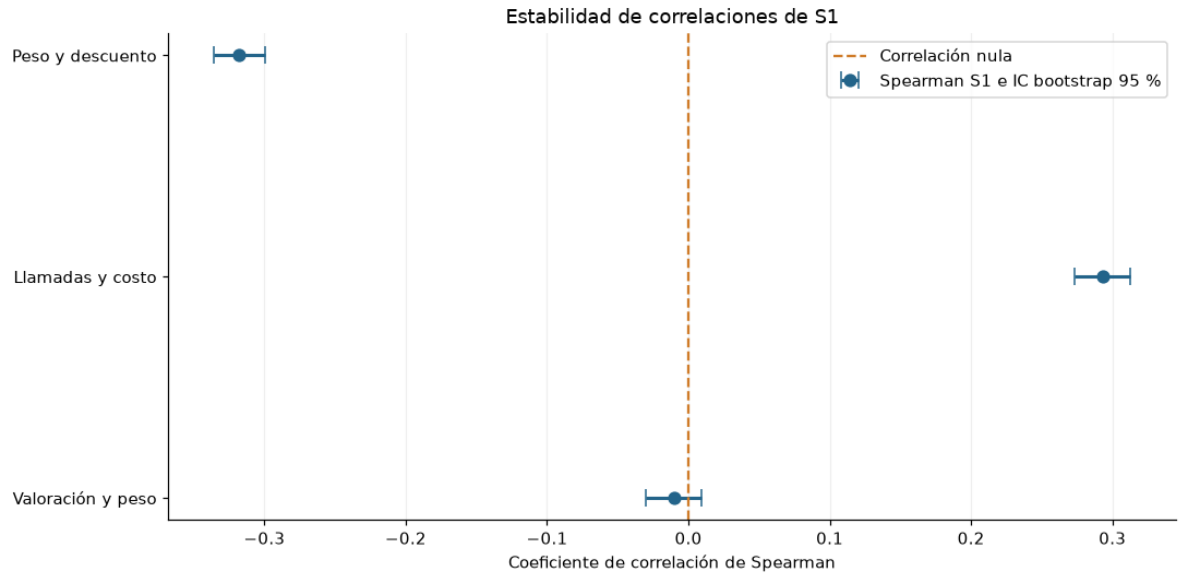
IV. ¿Qué correlaciones sobreviven al remuestreo?

Una correlación puntual de S1 no informa cuánto variaría su signo o magnitud al observar otra muestra de características semejantes. Para examinar esa incertidumbre, se seleccionaron tres relaciones de Spearman y se efectuaron 10.000 remuestras bootstrap de pares completos para cada una. Es esencial remuestrear juntas las dos variables: tratarlas como muestras independientes destruiría precisamente la asociación que se pretende estudiar. Se recalcularon los rangos y se respetaron los empates, frecuentes en variables discretas.

Tabla 3. Estabilidad de tres asociaciones monotónicas previamente estimadas en S1

Relación (n = 9.899)	ρ S1	IC bootstrap 95 %	Interpretación
Peso – descuento	−0,3177	[−0,3357; −0,2994]	Dirección negativa consistente
Llamadas – costo	0,2932	[0,2731; 0,3126]	Dirección positiva consistente
Valoración – peso	−0,0104	[−0,0299; 0,0092]	Signo no resuelto; relación pequeña

Figura 3. Coeficientes de Spearman con sus IC bootstrap del 95 %.



Nota. La línea discontinua representa ρ = 0; solo el tercer intervalo la atraviesa.

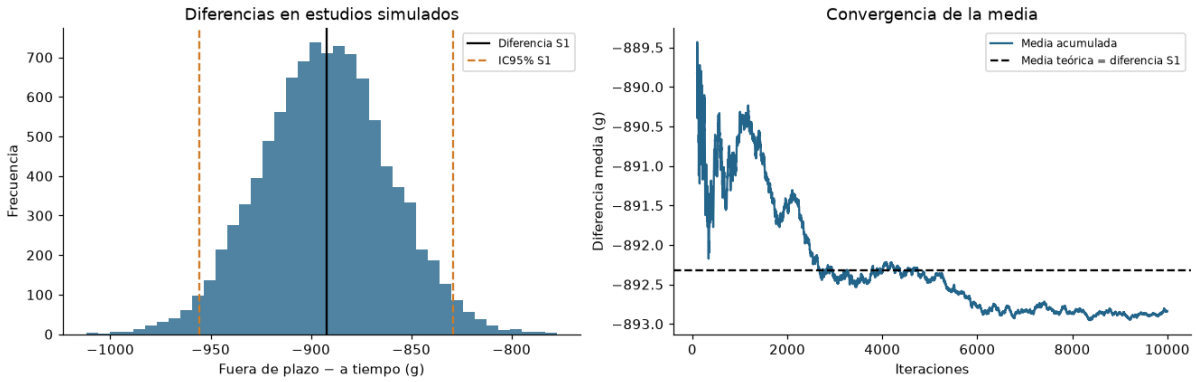
Peso–descuento y llamadas–costo mantienen sus signos en los intervalos estimados, de modo que su dirección no parece depender del azar de remuestreo bajo el procedimiento elegido. En cambio, valoración–peso presenta ρ cercano a cero y un intervalo que incluye cero: no se determina una dirección monotónica. Conviene distinguir este hallazgo de una supuesta «alta inestabilidad»: la banda es relativamente estrecha, pero está centrada alrededor de una asociación muy pequeña.

Hay una segunda distinción, particularmente relevante para S3: estabilidad ante bootstrap no equivale a robustez frente a decisiones analíticas. Al estudiar por separado los descuentos marcados como altos por la regla intercuartílica, la correlación peso–descuento pasa de −0,3177 a −0,0776. Su signo se mantiene, pero la magnitud se reduce considerablemente. Así, es defendible hablar de estabilidad direccional en la muestra original, pero no de una relación fuerte o invariable entre segmentos de productos. Tampoco la correlación aporta por sí misma evidencia causal ni demuestra utilidad predictiva.

V. Monte Carlo: precisión, cobertura y validez del modelo

La pregunta de simulación fue cuánto varía la diferencia de peso medio Δ = media(atrasados) − media(puntuales) si se repite un estudio del tamaño de S1 bajo distribuciones hipotéticas. Cada población simulada se calibró exclusivamente con los parámetros de S1: n = 5.907, media = 3.274,03 g y DE = 1.577,85 g para atrasados; n = 3.992, media = 4.166,35 g y DE = 1.574,66 g para puntuales. Se eligieron distribuciones lognormal y Gamma porque producen valores positivos y permiten asimetrías diferentes. La construcción siguió 10.000 estudios independientes por familia y semillas explícitas (Robert y Casella, 2004).

Figura 4. Diferencias simuladas y convergencia de su media bajo lognormal.

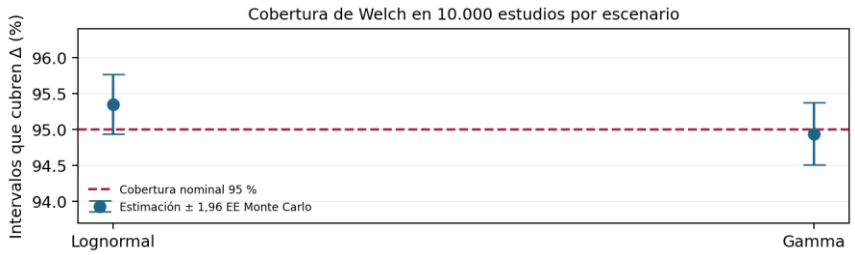


Nota. La media final fue −892,84 g, próxima al parámetro de entrada Δ = −892,32 g.

La media Monte Carlo terminó en −892,84 g para lognormal y −892,73 g para Gamma; el bootstrap independiente por grupos entregó también aproximadamente −892,84 g. El error de simulación de la media lognormal fue 0,319 g y los percentiles se estabilizaron al aumentar de 5.000 a 10.000 iteraciones. Estos resultados demuestran precisión numérica para estimar el comportamiento del escenario formulado. No son una confirmación independiente del valor de Δ, puesto que las distribuciones se calibraron precisamente para reproducir las medias de S1.

Se introdujo una validación adicional de la inferencia: en cada estudio simulado se construyó un intervalo de Welch usando las varianzas muestrales generadas y se registró si cubría la diferencia poblacional fijada por el modelo. Las coberturas empíricas fueron 95,35 % con lognormal y 94,94 % con Gamma, cercanas al 95 % nominal. Esto permite sostener que, bajo estos tamaños muestrales y familias generadoras, el método de Welch conserva una calibración adecuada de sus intervalos aun con asimetría.

Figura 5. Cobertura empírica del IC de Welch en dos escenarios simulados.



Nota. 10.000 estudios por familia; barras de incertidumbre Monte Carlo y referencia nominal del 95 %.

La validez externa es una pregunta distinta: en el grupo puntual, el cuantil 95 observado fue 5.863 g, mientras que lognormal y Gamma produjeron aproximadamente 7.109 y 7.048 g. En consecuencia, ambos modelos representan deficientemente ciertas colas de la distribución empírica. La convergencia y la cobertura condicional no prueban bondad de ajuste global, predicción de retrasos ni causalidad; delimitan qué inferencias son fiables dentro de los escenarios simulados.

VI. Robustez: influencia, outliers y supuestos alternativos

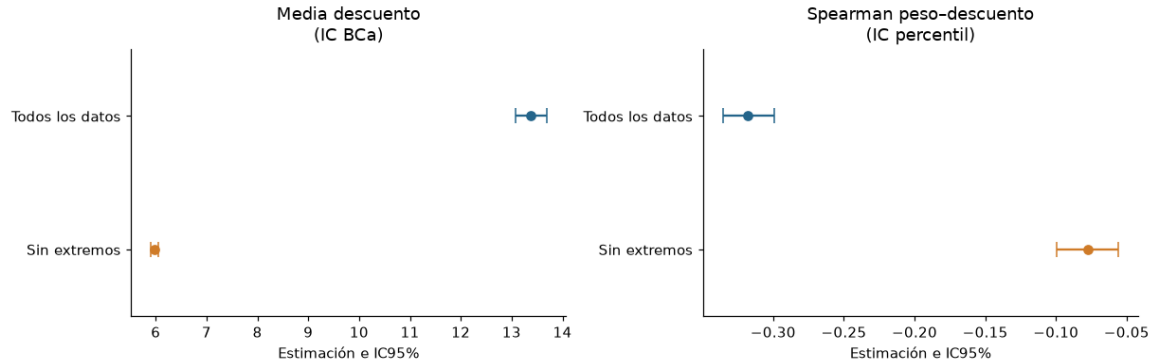
Los resultados inferenciales pueden ser sensibles a unas pocas observaciones o a decisiones que modifican la composición de la muestra. Para distinguir ambos mecanismos se combinaron jackknife, análisis por rango intercuartílico, cambios de distribución generadora y una alternativa robusta a la diferencia de medias. El propósito no fue «limpiar» los datos hasta obtener conclusiones más favorables, sino identificar qué permanece y qué cambia bajo decisiones plausibles.

Influencia individual y sensibilidad colectiva

El jackknife recalculó cada media omitiendo un registro a la vez. Los cambios máximos absolutos fueron 0,426 g para peso, 0,0115 USD para costo y 0,0047 unidades para descuento; ninguno de ellos alcanzó 0,04 errores estándar de su estimación original. Por tanto, no se identificaron observaciones individuales capaces de dominar las medias. Sin embargo, la baja influencia de un caso aislado no descarta que un grupo relativamente numeroso de observaciones tenga un efecto colectivo apreciable.

Al aplicar 1,5 × rango intercuartílico no se detectaron extremos en peso ni costo, pero se marcaron 2.209 descuentos (20,08 % de los envíos). Como análisis de sensibilidad, su exclusión llevó la media del descuento de 13,373 a 5,975 (−55,32 %) y redujo Spearman peso–descuento de −0,3177 a −0,0776. Esto es una modificación importante del estimando y de la composición de la muestra: no permite calificar automáticamente esos descuentos como errores ni justificar eliminarlos del análisis principal.

Figura 6. Efecto del escenario sin descuentos elevados sobre media y correlación.



Nota. La exclusión se utiliza para examinar sensibilidad, no como procedimiento recomendado de depuración.

Estimadores alternativos y supuestos del contraste

La comparación lognormal–Gamma ya mostró que los resultados de la diferencia de medias son parecidos bajo dos formas distributivas, pero con limitaciones en los cuantiles. Como segunda comprobación, se recortó el 10 % de cada cola de peso dentro de cada grupo: la diferencia estimada fue −1.094,85 g, con IC bootstrap percentil [−1.172,14; −1.017,91] g. La dirección negativa permanece, aunque cambia la magnitud en aproximadamente 202,53 g respecto de Welch. Por ello, hablar de robustez del signo es más preciso que afirmar que los estimadores son intercambiables.

En conjunto, las medias de peso y costo son estables frente a omisiones individuales; la media del descuento y la magnitud de peso–descuento requieren cautela frente al filtrado de valores altos. La diferencia entre pesos por puntualidad conserva su dirección al variar métodos y escenarios, pero no su interpretación causal. Estas conclusiones ofrecen una jerarquía de fiabilidad para decidir qué resultados trasladar a S3.

VII. Síntesis crítica y preparación para la Sumativa 3

La validación computacional confirmó que los IC de las tres medias son próximos bajo t, percentil y BCa; las dos pruebas de permutación conservaron las decisiones de S1; y dos de tres correlaciones mantuvieron una dirección definida ante bootstrap. En contraste, el descuento se reveló especialmente sensible a la selección de observaciones y los modelos paramétricos para peso no reprodujeron bien algunas colas. Se distinguen, por tanto, resultados con incertidumbre de estimación controlada de afirmaciones sujetas a decisiones de análisis y supuestos sobre los datos.

Tabla 4. Resultados reutilizables, límites de interpretación y decisiones para S3

Evidencia validada	Precaución fundamental	Recomendación para S3
Medias e IC de S1	Independencia y selección no demostradas; MCAR artificial	Conservar IC clásicos y BCa; validar estrategias de imputación.
Transporte / puntualidad	p ≈ 0,689 no acredita equivalencia	No recomendar cambios de transporte con este contraste.
Peso / puntualidad	Diferencia robusta de signo, no causal	Estudiar segmentos y posibles variables de confusión.
Peso / descuento	Magnitud muy sensible a descuentos altos	Mantener registros y analizar subgrupos; revisar unidad.
Llamadas / costo; valoración / peso	Asociación no es predicción; signo del segundo incierto	Validar fuera de muestra; evitar priorizar relación casi nula.

Alcance y trazabilidad

La base no documenta suficientemente el mecanismo de muestreo ni la independencia de registros. Tampoco dispone de destinos, distancias, fechas o días efectivos de atraso, variables necesarias para atribuir posibles mecanismos logísticos. Los faltantes MCAR se introdujeron artificialmente; los valores verdaderos ocultados deben reservarse para evaluación de imputación, nunca emplearse inadvertidamente al ajustarla. No se realizó corrección conjunta por múltiples pruebas. Por estas razones, el estudio conserva un alcance inferencial exploratorio y no sostiene afirmaciones causales ni pronósticos operativos.

El notebook notebooks/sumativa_2.ipynb presenta 19 celdas de código ejecutadas y 15 controles internos satisfactorios. La implementación reutilizable reside en src/, incluida la clase SimuladorMonteCarlo, mientras data/processed/resultados_validos_s2.json conserva parámetros, resultados y recomendaciones. Los índices S1/ y S2/ facilitan localizar evidencias sin duplicarlas. Los resultados se pueden reproducir con las semillas y el CSV MCAR auditado mediante su huella SHA-256.

Referencias y materiales de verificación

Efron, B. y Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall.

Phipson, B. y Smyth, G. K. (2010). Permutation p-values should never be zero. Statistical Applications in Genetics and Molecular Biology, 9(1).

Robert, C. P. y Casella, G. (2004). Monte Carlo Statistical Methods (2.ª ed.). Springer.

Universidad Andrés Bello (2026). Sumativa 2. Informe 3: guía y rúbrica. MCDI501, Canvas.

Grupo 7 (2026). Sumativas 1 y 2: notebooks, módulos y resultados validados. Repositorio GitHub del proyecto.

Repositorio y evidencia: https://github.com/jorge170102/ESTAD-STICA-COMPUTACIONAL---Grupo-7--MCDI501.202682.1914.EL.ON