MCDI501
ESTADÍSTICA COMPUTACIONAL
SUMATIVA 1
INFORME TÉCNICO DE AVANCE DEL PROYECTO

Grupo 7 - Factores asociados con la puntualidad de envíos en comercio electrónico
E-Commerce Shipping / Customer Analytics

Integrantes: Felipe Palma Barrientos · Vicente Aguila Rojas · Cristian Grandon Grandon · Jorge Gutierrez Jaramillo
Curso: MCDI501 · Estadística Computacional
Programa: Magíster en Ciencia de Datos e Inteligencia Artificial
Fecha: 11 de octubre de 2026
Repositorio: github.com/jorge170102/ESTAD-STICA-COMPUTACIONAL---Grupo-7--MCDI501.202682.1914.EL.ON

Chile, octubre de 2026

I. Portada e índice

I. Portada e índice	1-2
II. Introducción y contextualización	2
III. Definición del problema y objetivos	3
IV. Aplicación de herramientas científicas y metodología	3
V. Preparación y auditoría de datos	4
VI. Análisis exploratorio y relaciones bivariadas	4-5
VII. Estimación puntual e intervalos de confianza	6
VIII. Pruebas de hipótesis	6-7
IX. Discusión, conclusiones y líneas de mejora	7
X. Bibliografía y reproducibilidad	8

II. Introducción y contextualización

La puntualidad del despacho es una dimensión relevante de las operaciones de comercio electrónico. Sin embargo, las tasas generales de cumplimiento pueden ocultar diferencias asociadas con el transporte, el peso de los productos, la importancia asignada a los pedidos o sus características comerciales. Este proyecto utiliza E-Commerce Shipping / Customer Analytics para desarrollar un flujo reproducible de preparación, descripción e inferencia estadística.

El análisis integra 10.999 observaciones correspondientes a envíos individuales y 12 variables. Se estudian la proporción de entregas fuera de plazo, las distribuciones de variables cuantitativas y las asociaciones del estado de entrega con el medio de transporte y el peso. Los resultados son observacionales y exploratorios: no autorizan atribuciones causales.

Síntesis ejecutiva

El 59,67 % de los registros se clasificó como fuera de plazo. La prueba chi-cuadrado no encontró evidencia suficiente de asociación entre método de envío y puntualidad ($p = 0,690$; V de Cramér = 0,008). En contraste, la diferencia de peso medio entre entregas fuera de plazo y puntuales fue -892,32 g (IC del 95 %: [-955,61; -829,02] g) sobre observaciones disponibles de la versión MCAR. Las conclusiones quedan condicionadas a los supuestos de muestreo e independencia.

III. Definición del problema y objetivos

Problema central: identificar patrones descriptivos y asociaciones estadísticas entre características de los envíos y su estado de entrega, evitando confundir diferencias observadas con mecanismos causales.

Pregunta de investigación: ¿se asocian el medio de transporte y el peso del producto con la puntualidad de entrega en el conjunto analizado?

Objetivo general: caracterizar el conjunto E-Commerce Shipping mediante estadística descriptiva e inferencial, con un procedimiento documentado y reproducible.

- Examinar la estructura, dominios, integridad y valores faltantes del conjunto de datos.
- Describir las distribuciones de las variables y sus relaciones con el estado de entrega.
- Estimar tres medias con intervalos de confianza del 95 % y contrastar dos hipótesis al 5 %.
- Explicitar supuestos, limitaciones y proyecciones de trabajo posteriores.

IV. Aplicación de herramientas científicas y metodología

4.1. Entorno científico y arquitectura modular

El proyecto utiliza Python, pandas y NumPy para manipulación de datos, SciPy para inferencia, Matplotlib y Seaborn para visualización, Jupyter para registro ejecutable, y Git/GitHub para versionamiento. Las funciones reutilizables se organizan en src/ (carga, validación, transformación, análisis bivariado e inferencia); el notebook coordina el flujo, presenta evidencias y explica los resultados.

4.2. Procedimiento y criterios estadísticos

Se audita el CSV original; cuando no se detectan faltantes numéricos iniciales se generan ausencias MCAR con proporción de 10 % en Cost_of_the_Product y Weight_in_gms y semilla aleatoria 42. La versión procesada se conserva por separado junto con un registro de los valores retirados. La exploración y los contrastes usan los casos disponibles por variable, sin imputación en esta sumativa.

Se calculan frecuencias, medidas de tendencia central y dispersión, correlaciones de Spearman y gráficos comparativos. Para las medias se construyen intervalos t de Student al 95 %. Las hipótesis se evalúan mediante prueba chi-cuadrado de independencia y prueba bilateral t de Welch, ambas con nivel de significancia $\alpha = 0{,}05$.

4.3. Trazabilidad y reproducibilidad

Las versiones del dataset se distinguen entre data/raw y data/processed. El archivo requirements.txt documenta dependencias y las pruebas de código verifican propiedades del proceso. Para reproducir la entrega corresponde instalar dependencias y ejecutar «Restart Kernel and Run All» desde la raíz del repositorio con el CSV procesado validado.

V. Preparación y auditoría de datos

La unidad de observación es el envío y la variable objetivo Reached.on.Time_Y.N se interpreta en este estudio como 0 = a tiempo y 1 = fuera de plazo. ID corresponde a un identificador, por lo que no se incorpora a correlaciones ni a estimaciones numéricas.

Tabla 1. Resultados de la auditoría y generación controlada de faltantes

Control	Resultado	Decisión metodológica
Registros / variables	10.999 / 12	Conservar la base original
Nulos originales / duplicados	0 / 0	No imputar ni eliminar registros
Faltantes MCAR por variable	1.100 (10 %)	Peso y costo del producto
Semilla de generación	42	Reproducibilidad de la selección
Observaciones válidas en peso y costo	9.899 por variable	Análisis por casos disponibles

El mecanismo MCAR se aplicó con selección aleatoria, sin reemplazo y sin utilizar el valor de la variable para decidir su ocultamiento. Los valores completos originales permanecen disponibles como referencia de auditoría para una etapa futura de imputación. Este diseño no convierte la muestra en probabilística ni resuelve incertidumbres sobre su representatividad.

VI. Análisis exploratorio y relaciones bivariadas

6.1. Estadística descriptiva

Tabla 2. Medidas de tendencia central y dispersión sobre la versión MCAR

Variable	n válido	Media	DE muestral	Unidad
Llamadas de atención	10.999	4,054	1,141	Conteo
Compras anteriores	10.999	3,568	1,523	Conteo
Costo del producto	9.899	210,239	48,046	USD
Descuento ofrecido	10.999	13,373	16,206	No especificada
Peso del producto	9.899	3.633,880	1.636,133	Gramos

Tabla 3. Estado de entrega de los envíos

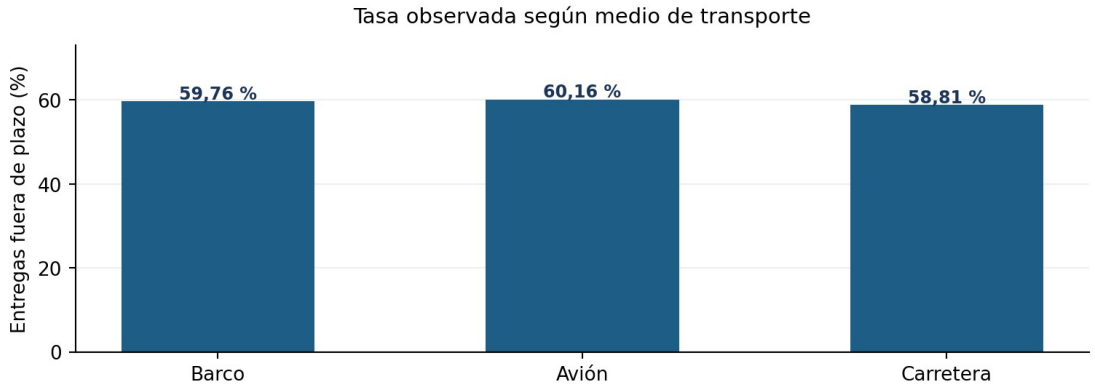
Estado	Frecuencia	Porcentaje
A tiempo (0)	4.436	40,33 %
Fuera de plazo (1)	6.563	59,67 %
Total	10.999	100,00 %

La proporción fuera de plazo alcanza casi seis de cada diez registros. El descuento presenta una media superior a su mediana (7), compatible con una distribución asimétrica a la derecha; su unidad no se especifica con certeza en la documentación. Las variables de costo y peso se estiman con 9.899 valores observados cada una.

6.2. Relaciones bivariadas y visualizaciones

La matriz de correlaciones de Spearman y los resúmenes por estado de entrega complementan la descripción univariada. En particular, se comparan las tasas de entregas fuera de plazo por modo de transporte y la distribución del peso según el resultado del envío. Estos gráficos resumen patrones descriptivos, no efectos causales.

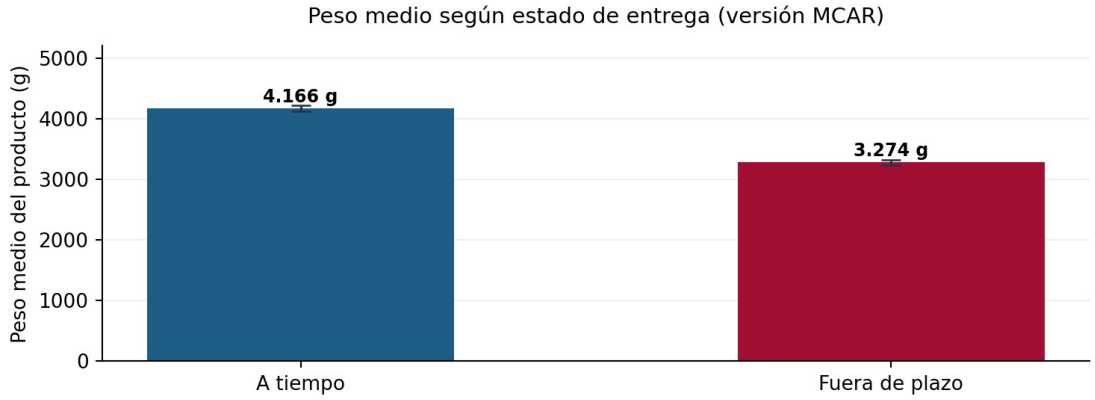
Figura 1. Porcentaje de entregas fuera de plazo según medio de transporte



Nota. Elaboración propia con datos E-Commerce Shipping. Denominadores: barco 7.462, avión 1.777 y carretera 1.760 envíos.

La mayor tasa corresponde al avión (60,16 %) y la menor a carretera (58,81 %), una diferencia descriptiva de solo 1,35 puntos porcentuales. Es necesario un contraste formal para determinar si la variación es estadísticamente distinguible de la esperable por azar bajo independencia.

Figura 2. Peso medio por estado de entrega en observaciones disponibles (MCAR)



Nota. Elaboración propia. Se excluyen solo pesos faltantes: n = 3.992 a tiempo y n = 5.907 fuera de plazo. Barras de error: ± 1,96 errores estándar, con finalidad descriptiva.

Las entregas puntuales tienen peso medio de 4.166,35 g frente a 3.274,03 g de las entregas fuera de plazo; la diferencia sin ajustar es de -892,32 g (fuera de plazo menos a tiempo).

VII. Estimación puntual e intervalos de confianza

Se construyen intervalos bilaterales para medias mediante la distribución t de Student y la desviación estándar muestral (IC = media ± t crítico × s/√n). El tamaño de muestra válido se informa por variable; la interpretación de cobertura depende de independencia, selección y variabilidad finita.

Tabla 4. Estimaciones de medias con intervalos de confianza del 95 %

Variable	n	Media	Límite inferior	Límite superior
Peso (g)	9.899	3.633,88	3.601,65	3.666,12
Costo del producto	9.899	210,24	209,29	211,19
Descuento ofrecido	10.999	13,37	13,07	13,68

Un intervalo de confianza del 95 % caracteriza la incertidumbre del estimador bajo repeticiones hipotéticas del procedimiento; no indica que el 95 % de los productos individuales se ubique entre sus límites. Los intervalos estrechos no eliminan posibles sesgos de selección.

VIII. Pruebas de hipótesis

8.1. Modo de envío y puntualidad: chi-cuadrado

H_0: el modo de envío y el estado de entrega son independientes. H_1: existe asociación. Se utiliza chi-cuadrado sobre una tabla de tres medios de transporte y dos estados, con α = 0,05. La frecuencia esperada mínima es 709,82, superior al umbral habitual de 5; la independencia entre envíos depende del diseño de recolección, no de esta tabla.

Tabla 5. Contraste de independencia por medio de transporte

χ^2	gl	p	V de Cramér	Decisión (α = 0,05)
0,743	2	0,690	0,008	No rechazar H_0

El p-valor de 0,690 no aporta evidencia suficiente contra la independencia entre transporte y puntualidad en estos registros. El V de Cramér de 0,008 indica una asociación observada prácticamente nula. No rechazar H_0 no significa demostrar independencia.

8.2. Peso promedio y puntualidad: t de Welch

H_0: μ fuera de plazo − μ a tiempo = 0. H_1: la diferencia es distinta de cero. Se utiliza Welch bilateral, que no exige igualdad de varianzas, con análisis gráfico de distribuciones y errores estándar. Los grupos son grandes; la independencia continúa siendo una suposición sustantiva.

8.2. Resultado de la prueba de Welch (continuación)

Tabla 6. Comparación de medias del peso según resultado del envío

Estadístico	Resultado	Interpretación
Diferencia media	−892,32 g	Fuera de plazo menos a tiempo
t de Welch	≈ −27,64	Contraste bilateral
Grados de libertad	≈ 8.576	Welch-Satterthwaite
p-valor	< 0,001	Rechazar H_0 al 5 %
IC del 95 %	[−955,61; −829,02] g	Diferencia poblacional estimada
d de Cohen	−0,566	Magnitud estandarizada moderada

La diferencia de peso es estadísticamente significativa y de magnitud apreciable. Sin embargo, el estudio no controla destinos, tipos de producto ni distancias: por tanto, la asociación encontrada no permite afirmar que cambiar el peso de un envío causaría un cambio en su puntualidad.

IX. Discusión, conclusiones y líneas de mejora

9.1. Discusión integrada

Los datos muestran que 59,67 % de los envíos aparecen fuera de plazo. El método de transporte exhibe tasas similares y un contraste no significativo; el peso sí presenta una diferencia media clara según estado de entrega. Interpretados conjuntamente, los resultados motivan examinar mecanismos logísticos adicionales, sin asumir que las variables estudiadas operen de manera independiente o causal.

9.2. Limitaciones y alcance

- La muestra disponible no acredita selección probabilística ni independencia estricta entre envíos.
- No se observan destino, distancia, fechas, duración real del retraso ni rutas de distribución.
- Los faltantes MCAR son artificiales y su patrón debe documentarse; no se imputaron para esta evaluación.
- Los dos contrastes fueron exploratorios con $\alpha = 0{,}05$ por prueba, sin corrección global por multiplicidad.
- La codificación del objetivo y la unidad del descuento deben corroborarse con la fuente original antes de inferir implicancias externas.

9.3. Conclusiones y continuidad

El proyecto integra auditoría, generación reproducible de faltantes, análisis descriptivo y dos métodos de inferencia en un flujo modular. La evidencia de esta muestra no respalda una asociación relevante del modo de transporte con la puntualidad, pero sí una diferencia de peso entre estados de entrega. En fases posteriores se recomienda comparar estrategias de imputación usando la auditoría como referencia de evaluación y explorar modelos multivariados con validación independiente.

X. Bibliografía y reproducibilidad

10.1. Fuentes de datos y documentos

1. Universidad Andrés Bello (2026). Sumativa 1: informe técnico de avance del proyecto [Instrucciones y rúbrica de MCDI501]. Material docente de la asignatura.

2. Kaggle. (s. f.). E-Commerce Shipping Data / Customer Analytics [Conjunto de datos]. https://www.kaggle.com/datasets/prachi13/customer-analytics

3. pandas Development Team. (s. f.). pandas documentation. https://pandas.pydata.org/docs/

4. SciPy Community. (s. f.). SciPy documentation. https://docs.scipy.org/doc/scipy/

5. NumPy Developers. (s. f.). NumPy documentation. https://numpy.org/doc/

6. Matplotlib Development Team. (s. f.). Matplotlib documentation. https://matplotlib.org/stable/

7. Python Software Foundation. (s. f.). Python documentation. https://docs.python.org/3/

10.2. Acceso al proyecto y trazabilidad

Repositorio del Grupo 7 (MCDI501): https://github.com/jorge170102/ESTAD-STICA-COMPUTACIONAL---Grupo-7--MCDI501.202682.1914.EL.ON

Tabla 7. Evidencia reproducible vinculada a la rúbrica

Elemento evaluado	Evidencia técnica
Preparación y calidad	src/carga.py, src/validacion.py, src/transformacion.py
Estadística descriptiva	Notebook: secciones de exploración y tablas
Relaciones bivariadas	src/analisis_bivariado.py y visualizaciones
Intervalos y contrastes	src/inferencia.py; notebook de inferencia
Verificación	Pruebas reejecutables en tests/
Informe técnico	Documento PDF y código en el repositorio

10.3. Procedimiento de reproducción

Desde la raíz del proyecto: 1) crear y activar un entorno virtual; 2) instalar requirements.txt; 3) abrir notebooks/sumativa_1.ipynb; 4) seleccionar el kernel correspondiente; 5) ejecutar «Restart Kernel and Run All» y contrastar los resultados con data/processed/ecommerce_mcar.csv. Mantener el registro de valores MCAR separado y sin utilizarlo para completar artificialmente esta sumativa.

Los resultados son provisionales en términos de inferencia poblacional y deben acompañarse de la discusión de supuestos, limitaciones y alcance observacional declarada en este informe.