

Factores asociados con la puntualidad de envíos en comercio electrónico

Análisis descriptivo e inferencial del conjunto E-Commerce Shipping

UNIVERSIDAD ANDRÉS BELLO · MAGÍSTER EN CIENCIA DE DATOS E IA

Asignatura	Equipo	Versión
Estadística Computacional (MCDI501)	Grupo 7	Borrador 01 · 10/10/2026

Resumen ejecutivo

Este informe presenta el avance del proyecto de Estadística Computacional orientado a caracterizar las operaciones de despacho y explorar factores asociados con las entregas fuera de plazo. Se utiliza el dataset E-Commerce Shipping / Customer Analytics, compuesto por 10.999 observaciones y 12 variables.

La revisión inicial del conjunto original identificó ausencia de nulos y duplicados exactos. Para ajustarse al diseño metodológico del curso, se generó una versión MCAR con 10 % de valores faltantes en peso y costo del producto, conservando un registro de los valores originales.

La tasa observada de entregas fuera de plazo es 59,67 %. En las comparaciones descriptivas, los métodos de transporte presentan tasas similares; en cambio, el peso medio difiere entre los dos estados de entrega. Las pruebas estadísticas preliminares de la página 6 cuantifican estas relaciones.

ESTADO DEL DOCUMENTO: borrador académico en desarrollo. Las estimaciones e hipótesis de la página 6 fueron calculadas a partir del CSV procesado del repositorio para iniciar el informe, pero aún deben incorporarse al notebook oficial y validarse mediante una ejecución integral antes de la entrega.

Fecha límite en Canvas: 14 de octubre de 2026, 08:00 h. Extensión máxima de la entrega final: 8 páginas, sin anexos.

01 / PLANTEAMIENTO

Problema y objetivos

Contexto del problema

En entornos de comercio electrónico, la puntualidad del despacho afecta la planificación logística y la experiencia de los clientes. Analizar qué características acompañan a las entregas fuera de plazo aporta evidencia preliminar para priorizar futuras investigaciones y formular modelos de clasificación. El alcance del presente estudio es asociativo: no permite inferir causalidad.

Pregunta de investigación

¿Qué características de los envíos, particularmente su modalidad de transporte y el peso del producto, se relacionan con la ocurrencia de entregas fuera de plazo en el conjunto de datos disponible?

Objetivo general

Caracterizar el conjunto de datos E-Commerce Shipping y examinar, mediante estadística descriptiva e inferencial, la asociación entre las características de los pedidos y la puntualidad de sus entregas.

Objetivos específicos

- Inspeccionar estructura, tipos de variables, integridad y coherencia de los registros.
- Describir numérica y gráficamente las principales variables y sus distribuciones.
- Obtener estimaciones puntuales e intervalos de confianza del 95 % para tres magnitudes.
- Contrastar dos hipótesis estadísticas relevantes y evaluar sus supuestos y tamaños del efecto.
- Documentar hallazgos, límites de interpretación y próximos pasos reproducibles.

Fuente y unidad de análisis

La unidad de observación es un envío, identificado mediante ID. Se utilizan los 10.999 registros del archivo `customer_analytics.csv` disponible en el repositorio del Grupo 7, correspondiente al dataset divulgado como E-Commerce Shipping / Customer Analytics.

Elemento	Definición
Variable respuesta	Reached.on.Time_Y.N (0 = entrega a tiempo; 1 = fuera de plazo, según la codificación asumida en el notebook).
Variables de estudio	Peso, costo, descuento, modo de envío, bloque de almacén, calificación, compras previas y llamadas.
Cobertura	Un conjunto de datos de comercio electrónico; sin evidencia documental suficiente para asumir representatividad poblacional.

02 / MÉTODO

Preparación y calidad de los datos

Arquitectura y reproducibilidad

La implementación organiza la carga, la validación y la transformación en módulos Python independientes (src/carga.py, src/validacion.py y src/transformacion.py). El notebook notebooks/sumativa_1.ipynb ejecuta estas funciones y presenta la auditoría. El repositorio incluye pruebas automáticas para la conservación del original y la reproducibilidad de la generación MCAR.

Auditoría inicial del dataset original

Indicador	Resultado	Interpretación
Observaciones	10.999	Unidad: envío individual
Variables	12	Campos cuantitativos, ordinales y nominales
Nulos iniciales	0	No se requieren imputaciones sobre el archivo original
Duplicados exactos	0	No se detectaron registros completos repetidos
Identificadores	Únicos	ID no se utiliza como predictor numérico

Construcción de la versión con faltantes

Como el archivo de origen está completo, se generaron faltantes completamente al azar (MCAR) con semilla 42, eliminando 1.100 valores (10 % aproximadamente) en Weight_in_gms y otros 1.100 en Cost_of_the_Product. Las posiciones se seleccionan aleatoriamente por columna, sin reemplazo, y los valores retirados se almacenan con su identificador para futuras evaluaciones de imputación.

Archivo	Uso
data/raw/customer_analytics.csv	Fuente original, sin modificaciones
data/processed/ecommerce_mcar.csv	Versión de trabajo con faltantes artificiales
data/processed/valores_originales_mcar.csv	Auditoría de valores retirados artificialmente

PUNTO A RESOLVER: en la versión actual del notebook, la exploración descriptiva y bivariada utiliza df_original. Antes de entregar debe adoptarse una política coherente para realizar el análisis sobre la versión MCAR, indicando el tratamiento de casos completos por variable y sin usar los valores conservados para imputar.

03 / ANÁLISIS EXPLORATORIO

Caracterización descriptiva

La exploración documentada en el notebook calcula medidas de posición, dispersión, cuartiles y valores extremos por el criterio de 1,5 IQR. También incorpora frecuencias absolutas y relativas para las variables categóricas y ordinales, histogramas y diagramas de caja.

Medidas resumen del conjunto original

Variable	Media	DE muestral	Unidad / escala
Llamadas al cliente	4,054	1,141	Conteo
Compras previas	3,568	1,523	Conteo
Costo del producto	210,197	48,063	USD, según diccionario del notebook
Descuento ofrecido	13,373	16,206	Unidad no especificada en fuente
Peso del producto	3.634,017	1.635,377	Gramos

Los promedios y desviaciones anteriores corresponden al análisis del archivo original, tal como quedó ejecutado en el notebook. No se deben mezclar sin advertencia con los intervalos de confianza calculados más adelante sobre ecommerce_mcar.csv.

Estado de entrega

Categoría	Registros	Porcentaje
A tiempo (0)	4.436	40,33 %
Fuera de plazo (1)	6.563	59,67 %
Total	10.999	100,00 %

Interpretación exploratoria

La categoría “fuera de plazo” concentra cerca de seis de cada diez registros. El descuento ofrecido presenta mayor dispersión relativa que el costo del producto y exhibe asimetrías que deberán discutirse al realizar la inferencia. La identificación de valores extremos mediante IQR es una señal de revisión, no justifica eliminarlos automáticamente.

La clasificación 0/1 utilizada en el presente borrador reproduce el criterio consignado por el equipo en el notebook. Antes de entregar, conviene corroborarla con la documentación original de la fuente y mantenerla uniforme en gráficos, hipótesis e informe.

04 / RELACIONES BIVARIADAS

Asociaciones con la puntualidad

Transporte y entregas fuera de plazo

El análisis bivariado del notebook calcula tasas de entregas fuera de plazo por modalidad, bloque de almacén e importancia del producto. Los porcentajes se estiman dentro de cada categoría para evitar comparaciones sesgadas por tamaños de grupo diferentes.




Figura 1. Tasa de entregas fuera de plazo por método de transporte; 10.999 observaciones.

Método	Total	Fuera de plazo	Tasa
Barco	7.462	4.459	59,76 %
Avión	1.777	1.069	60,16 %
Carretera	1.760	1.035	58,81 %

Las diferencias descriptivas por método son pequeñas: la mayor tasa observada (avión) supera a la menor (carretera) en 1,35 puntos porcentuales. Esto requiere una prueba de independencia para establecer si el patrón es compatible con fluctuaciones muestrales.

Peso del producto según estado de entrega




Figura 2. Comparación de pesos medios con datos válidos de la versión MCAR (n = 9.899).

En los registros válidos de la versión procesada, el peso promedio fue 4.166,35 g en entregas a tiempo y 3.274,03 g en entregas fuera de plazo. Esta diferencia es descriptiva y no controla otras variables potencialmente asociadas con el despacho.

05 / INFERENCIA PRELIMINAR

Estimaciones y pruebas estadísticas

Los siguientes resultados fueron calculados para este borrador usando los estadísticos de la versión procesada ecommerce_mcar.csv. Su incorporación y verificación dentro del notebook oficial es una tarea pendiente antes de presentar el trabajo como entrega completa.

Estimaciones puntuales e intervalos al 95 %

Se aplicó el intervalo bilateral t de Student para la media: $\text{media} \pm t \text{ crítico} \times s / \sqrt{n}$, usando observaciones válidas de cada variable. Su interpretación poblacional requiere supuestos de independencia y pertinencia del proceso muestral que no están plenamente documentados.

Variable	n válido	Media	IC del 95 % para la media
Peso (g)	9.899	3.633,88	[3.601,65; 3.666,12]
Costo del producto	9.899	210,24	[209,29; 211,19]
Descuento ofrecido	10.999	13,37	[13,07; 13,68]

Contraste 1. Transporte y puntualidad

H_0 : el método de transporte y el estado de entrega son independientes. H_1 : existe asociación entre ambas variables. Se empleó chi-cuadrado de Pearson con $\alpha = 0,05$. Las frecuencias esperadas superaron 5 (mínima $\approx 709,8$).

Resultado preliminar: $\chi^2(2) = 0,743$; $p = 0,690$; V de Cramér = 0,008. No se rechaza H_0 al 5 %: no se obtiene evidencia de una asociación estadística apreciable entre modalidad de transporte y estado de entrega en estos registros.

Contraste 2. Peso medio y puntualidad

H_0 : la media del peso es igual en ambos estados. H_1 : las medias difieren. Se utilizó t de Welch bilateral ($\alpha = 0,05$), sin exigir igualdad de varianzas, con $n = 3.992$ envíos a tiempo y $n = 5.907$ fuera de plazo.

Resultado preliminar: diferencia (fuera de plazo – a tiempo) = $-892,32$ g; $t \approx -27,64$; $gl \approx 8.576$; $p < 0,001$; IC 95 % de la diferencia $[-955,61; -829,02]$ g; d de Cohen $\approx -0,566$. Existe evidencia de diferencia de medias en este conjunto, pero no de efecto causal del peso sobre el retraso.

06 / SÍNTESIS Y CONTINUIDAD

Discusión, limitaciones y próximos pasos

Conclusiones preliminares

La auditoría confirma que el dataset original es estructuralmente utilizable: posee 10.999 envíos, 12 variables, sin nulos originales ni duplicados exactos. La versión MCAR permite abordar la imputación en fases posteriores sin alterar la fuente inicial.

Descriptivamente, el 59,67 % de los registros se clasifica como fuera de plazo conforme a la codificación adoptada por el equipo. La comparación entre métodos de transporte arroja diferencias porcentuales mínimas; el contraste chi-cuadrado preliminar no identifica asociación estadísticamente significativa. En cambio, el peso medio muestra una diferencia significativa entre los estados de entrega.

Estos hallazgos sirven para orientar preguntas y modelos posteriores, no para formular recomendaciones operativas causales. Una muestra de comercio electrónico no necesariamente representa a todas las empresas, rutas ni periodos de operación.

Limitaciones metodológicas

- Los registros no incluyen distancias de viaje, tiempos reales, ubicaciones de entrega ni información operacional suficiente para aislar mecanismos de retraso.
- La fuente y el procedimiento de selección de observaciones no permiten asegurar representatividad ni independencia estricta.
- El notebook aún explora el archivo original en lugar de la versión MCAR; los resultados inferenciales deben incorporarse y reproducirse en el flujo oficial.
- La significancia estadística no acredita causalidad ni relevancia operativa; deben considerarse magnitudes, sesgos y variables de confusión.

Próximos pasos antes de la entrega

1) Unificar la política de datos para EDA e inferencia. 2) Implementar `src/estimacion.py` y `src/hipotesis.py` con pruebas, verificación de supuestos e interpretación automatizada. 3) Ejecutar el notebook completo desde cero. 4) Incorporar gráficos seleccionados y referencias definitivas, verificar la codificación de la variable objetivo y cerrar las ocho páginas máximas permitidas.

Fuentes y reproducibilidad

Universidad Andrés Bello (2026). “Sumativa 1: Informe técnico de avance del proyecto”, instrucciones y rúbrica de MCDI501; Maidana, J. P. (2026), “Bases de datos disponibles para el proyecto del curso”.

Repositorio del Grupo 7: <https://github.com/jorge170102/ESTAD-STICA-COMPUTACIONAL---Grupo-7--MCDI501.202682.1914.EL.ON> (revisión del commit 122523e).

Fuente del dataset: <https://www.kaggle.com/datasets/prachi13/customer-analytics>